1. Fundamentos del Agrupamiento

Definición 1: Agrupamiento.
Sea $X = \{x_1, x_2, \ldots, x_n\}$ un conjunto de datos. El agrupamiento consiste en organizar los datos en subconjuntos llamados *clusters*, de modo que los elementos dentro de cada grupo sean más similares entre sí que con los de otros grupos.

Definición 2: Agrupamiento exclusivo (partición).
Un agrupamiento exclusivo de X es una familia de subconjuntos

$$C_1, C_2, \ldots, C_k$$

tal que:

- $C_i \neq \varnothing$ para todo i,
- $C_i \cap C_j = \varnothing$ si $i \neq j$,
- $\bigcup_{i=1}^{k} C_i = X$.

Definición 3: Agrupamiento con superposición.
Un agrupamiento con superposición permite que un mismo dato pertenezca a varios clusters. Es decir, existen $i \neq j$ tales que:

$$C_i \cap C_j \neq \varnothing.$$

Este tipo de agrupamiento modela situaciones donde un elemento puede compartir características de múltiples grupos.

Definición 4: Agrupamiento difuso.
En el agrupamiento difuso, cada dato $x \in X$ tiene un grado de pertenencia a cada cluster, dado por:

$$u_{ij} \in [0, 1], \quad \sum_{j=1}^{k} u_{ij} = 1.$$

Esto permite describir pertenencias parciales en lugar de asignaciones estrictas.

Definición 5: Estructura de un cluster.
Un cluster puede caracterizarse por:

- **Centro**: punto representativo del grupo (por ejemplo, media o centroide),
- **Dispersión**: variabilidad interna del cluster,

- **Separación**: distancia respecto a otros clusters.

DEFINICIÓN 6: Problema general de agrupamiento.
Dado un conjunto de datos X y una medida de similitud o distancia, el problema de agrupamiento consiste en encontrar una partición o estructura de clusters que optimice un criterio de cohesión interna y separación externa.

2. MÉTRICAS DE AGRUPAMIENTO

Dado un agrupamiento de datos $\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$, donde cada C_i es un conjunto de datos que representa un clúster, tenemos las siguientes definiciones

- **Centroide del clúster:** Es el punto medio del clúster, calculado como el promedio de todos los puntos en el clúster

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x.$$

- **Diámetro del clúster:** Mide la distancia máxima entre dos puntos dentro del mismo clúster

$$\mathrm{diam}(C_i) = \max_{x,y \in C_i} d(x, y).$$

- **Inercia:** Mide la cohesión interna de los clústeres, definida como la suma de las distancias cuadráticas entre cada punto y el centroide de su clúster

$$I_i = \sum_{x \in C_i} d(x, \mu_i)^2.$$

- **Distancia promedio dentro del clúster:** Mide la distancia promedio entre los puntos y el centroide del clúster

$$S_i = \frac{1}{|C_i|} \sum_{x \in C_i} d(x, \mu_i).$$

- **Cohesión de Silueta:** Mide la distancia promedio entre un punto y todos los demás puntos en el mismo clúster, para $x \in C_i$

$$a(x) = \frac{1}{|C_i| - 1} \sum_{y \in C_i} d(x, y).$$

- **Distancia entre clústeres:** Mide la distancia mínima entre puntos de dos clústeres diferentes

$$d(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y).$$

- **Distancia entre centroides:** Mide la distancia entre los centroides de dos clústeres

$$d_c(C_i, C_j) = d(\mu_i, \mu_j).$$

- **Separación de Silueta:** Mide la distancia promedio entre un punto y todos los puntos en el clúster más cercano al que no pertenece, para $x \in C_i$

$$b(x) = \min_{j \neq i} \frac{1}{|C_j|} \sum_{y \in C_j} d(x, y).$$

Con esto, definimos las siguientes métricas de evaluación:

Medida	**Definición**
Inercia total	$I_{total} = \sum_{i=1}^{K} I_i = \sum_{i=1}^{K} \sum_{x \in C_i} d(x, \mu_i)^2$
Índice de Davies-Bouldin	$DB = \frac{1}{K} \sum_{i=1}^{K} \max_{j \neq i} \left(\frac{S_i + S_j}{d_c(C_i, C_j)} \right)$
Índice de Dunn	$Dunn = \frac{\min_{i \neq j} d(C_i, C_j)}{\max_{1 \leqslant k \leqslant K} diam(C_k)}$
Índice de Silueta	$S = \frac{1}{\lvert D \rvert} \sum_{i=1}^{\lvert D \rvert} \frac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}$