1. Algoritmos Jerárquicos

1.1 Algoritmo Aglomerativo

Algoritmo 1
Pseudocódigo del agrupamiento jerárquico aglomerativo (AHC)

Entrada: D (conjunto de datos individuales)
Salida : Estructura jerárquica de clústeres
Inicializar $\ell \leftarrow 0$;
Inicializar el conjunto de clústeres $C_\ell \leftarrow D$;
mientras $|C_\ell| > 1$ **hacer**
  Encontrar par $c_i, c_j \in C_\ell$ tal que $L(c_i, c_j)$ sea mínima;
  Crear nuevo clúster $c_* \leftarrow c_i \cup c_j$;
  Actualizar $C_{\ell+1} \leftarrow (C_\ell \setminus \{c_i, c_j\}) \cup \{c_*\}$;
  $\ell \leftarrow \ell + 1$;
devolver C_ℓ

1.2 Tipos de enlace

Definición 1: Función de enlace.
Una función de enlace es una función

$$L\colon \mathcal{P}(X) \times \mathcal{P}(X) \to \mathbb{R}$$

que asigna una distancia entre dos clústeres A y B, dada una distancia d entre puntos de X.

Definición 2: Enlace simple.
La distancia entre dos clústeres es la distancia mínima entre los puntos de ambos clústeres. Es decir, dados A y B dos conjuntos, la distancia entre ellos es:

$$L(A, B) = \min_{x \in A, y \in B} d(x, y)$$

Definición 3: Enlace completo.
La distancia entre dos clústeres es la distancia máxima entre los puntos de ambos clústeres. Es decir, dados A y B dos conjuntos, la distancia entre ellos es:

$$L(A, B) = \max_{x \in A, y \in B} d(x, y)$$

DEFINICIÓN 4: Enlace promedio.
La distancia entre dos clústeres es el promedio de las distancias entre los puntos de ambos clústeres. Es decir, dados A y B dos conjuntos, la distancia entre ellos es:

$$L(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} d(x, y)$$

DEFINICIÓN 5: Enlace de centroide.
La distancia entre dos clústeres es la distancia entre los centroides de ambos clústeres. Es decir, dados A y B dos conjuntos, la distancia entre ellos es:

$$L(A, B) = d\left(\frac{1}{|A|} \sum_{x \in A} x, \frac{1}{|B|} \sum_{y \in B} y\right)$$

1.3 Algoritmo Divisivo

Algoritmo 2
Pseudocódigo del agrupamiento jerárquico divisivo (DHC)

Entrada: D (conjunto de datos individuales)
Salida : Estructura jerárquica de clústeres
Inicializar $\ell \leftarrow 0$;
Inicializar el conjunto de clústeres $C_\ell \leftarrow \{D\}$;
mientras *exista* $c \in C_\ell$ *que se pueda dividir* **hacer**
  Seleccionar clúster $c \in C_\ell$ para dividir;
  Dividir c en subclústeres $c_1, c_2, \ldots, c_k$;
  Actualizar $C_{\ell+1} \leftarrow (C_\ell \setminus \{c\}) \cup \{c_1, c_2, \ldots, c_k\}$;
  $\ell \leftarrow \ell + 1$;
devolver C_ℓ

2. Agrupamiento k-Means

Algoritmo 3

Pseudocódigo del algoritmo k-means

Entrada: D (conjunto de datos) y k (número de clústeres)
Salida : El conjunto de clústeres P
Inicializar los clústeres vacíos $P \leftarrow \{p_1, p_2, \ldots, p_k\}$;
Seleccionar los *centroides* iniciales $\zeta_1, \zeta_2, \ldots, \zeta_k$;
mientras *Condición de parada no satisfecha* **hacer**
  `/* Fase de asignación */`
  para *todo* $d_i \in D$ **hacer**
    Encontrar el índice j tal que la distancia $d(d_i, \zeta_j)$ sea mínima;
    Asignar la instancia d_i al clúster p_j;
  `/* Fase de actualización */`
  para *todo* $p_i \in P$ **hacer**
    Recalcular ζ_i como el promedio de los puntos $d \in p_i$;
devolver P