1. Support Vector Machine (SVM)

Vladimir Vapnik dijo: *«No existe nada más práctico que una buena teoría»*.

Definición 1.
Sea un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^{N}$ donde $x_i \in \mathbb{R}^n$ son los vectores de características y $y_i \in \{-1, 1\}$ son las etiquetas de clase.
El modelo SVM busca determinar un hiperplano, definido por

$$w \cdot x + b = 0,$$

que separe los datos, es decir

$$w \cdot x_i + b \geqslant 1 \text{ si } y_i = 1 \qquad \text{y} \qquad w \cdot x_i + b \leqslant -1 \text{ si } y_i = -1.$$

La condición puede tomarse como:

$$y_i(w \cdot x_i + b) \geqslant 1$$

A los vectores que alcanzan la igualdad de la condición, es decir, $y_i(w \cdot x_i + b) = 1$, se los llama **vectores de soporte**.

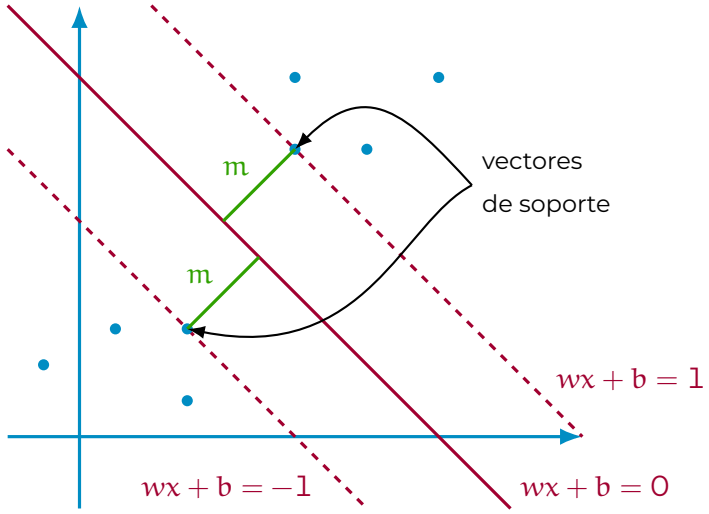

La distancia de los vectores de soporte al hiperplano separador es m (margen). El objetivo es maximizar el margen, que es la distancia entre los hiperplanos por los que pasan los vectores de soporte: $2m$.

Para determinar el valor de t, consideremos momentáneamente que el hiperplano pasa por el origen (es decir, $b = 0$).

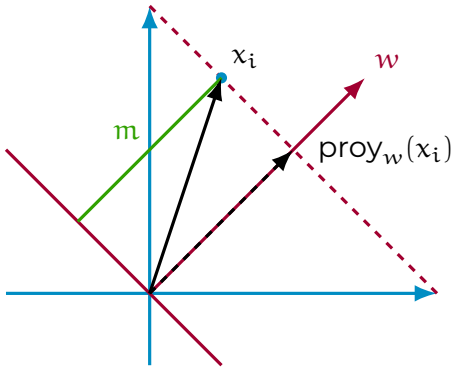

La distancia m desde el punto x_i al hiperplano se puede calcular como la norma de la proyección del vector x_i sobre el vector normal al hiperplano w:

$$m = \|\text{proy}_w(x_i)\| = \left\| \frac{x_i \cdot w}{\|w\|^2} \cdot w \right\|,$$

además, como x_i está sobre el hiperplano de ecuación $w \cdot x = 1$, se cumple que $w \cdot x_i = 1$. Por lo tanto:

$$m = \left\| \frac{1}{\|w\|^2} \cdot w \right\| = \frac{1}{\|w\|}.$$

Con esto, lo que debemos maximizar es $2m = \frac{2}{\|w\|}$, lo cual es equivalente a minimizar $\frac{1}{2}\|w\|$; por conveniencia, se minimiza el cuadrado de la norma. Así, el problema de optimización queda:

$$\begin{cases} \text{mín} \quad f(w, b) = \dfrac{1}{2}\|w\|^2 \\ \text{sujeto a} \\ \qquad y_i(w \cdot x_i + b) \geqslant 1, \quad i = 1, \ldots, N \end{cases}$$

Para resolver este problema de optimización con restricciones, se utiliza el método de los multiplicadores de Lagrange. Planteamos el Lagrangiano usando multiplicadores de Lagrange $\alpha_i \geqslant 0$:

$$L(w, b, \alpha_1, \ldots, \alpha_N) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^{N} \alpha_i \left(y_i(w \cdot x_i + b) - 1 \right),$$

desarrollando:

$$L(w, b, \alpha_1, \ldots, \alpha_N) = \frac{1}{2} w \cdot w - w \cdot \sum_{i=1}^{N} \alpha_i y_i x_i - b \sum_{i=1}^{N} \alpha_i y_i + \sum_{i=1}^{N} \alpha_i.$$

Con esto, obtenemos las condiciones de pptimalidad,derivando parcialmente el Lagrangiano con respecto a w y b e igualando a cero:

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^{N} \alpha_i y_i x_i = 0 \quad \Rightarrow \quad w = \sum_{i=1}^{N} \alpha_i y_i x_i$$

y

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{N} \alpha_i y_i = 0 \quad \Rightarrow \quad \sum_{i=1}^{N} \alpha_i y_i = 0.$$

Reemplazamos las condiciones de optimalidad en el Lagrangiano para obtener el problema dual:

$$L(w, b, \alpha_1, \ldots, \alpha_N) = \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j).$$

El problema dual de maximización es:

$$\begin{cases} \text{máx} \quad L_D(\alpha_1, \ldots, \alpha_N) = \displaystyle\sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ \text{sujeto a} \\ \qquad \alpha_i \geqslant 0, \quad i = 1, \ldots, N, \\ \qquad \displaystyle\sum_{i=1}^{N} \alpha_i y_i = 0. \end{cases}$$

1.1 Funciones kernel

Definición 2.
Una función kernel es una función

$$K \colon \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$$

que cumple las propiedades distributiva, conmutativa y semidefinida positiva.

Dada una función de mapeo

$$\phi \colon \mathbb{R}^n \to \mathbb{R}^m,$$

se define el kernel asociado como

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j).$$

Al usar funciones kernel, el problema dual de maximización queda:

$$\begin{cases} \text{máx} \quad L_D(\alpha_1, \ldots, \alpha_N) = \displaystyle\sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{sujeto a} \\ \qquad \alpha_i \geqslant 0, \quad i = 1, \ldots, N, \\ \qquad \displaystyle\sum_{i=1}^{N} \alpha_i y_i = 0. \end{cases}$$

Algunas funciones kernel comunes son:

- Kernel lineal: $K(x_i, x_j) = x_i \cdot x_j$.
- Kernel polinomial: $K(x_i, x_j) = (\alpha x_i \cdot x_j + c)^p$, con $\alpha > 0$, $c \geqslant 0$ y $p \in \mathbb{N}$.
- Kernel radial: $K(x_i, x_j) = \exp\left(-\alpha \|x_i - x_j\|^2\right)$, con $\alpha > 0$.

2. Árboles de Decisión

Definición 3: Árbol de decisión.
Un **árbol de decisión** es un modelo de aprendizaje supervisado que representa una función

$$f : \mathbb{R}^n \to Y$$

mediante una estructura jerárquica de decisiones.
Cada nodo interno realiza una partición del espacio de características según una regla del tipo

$$x_j \leqslant t,$$

y cada hoja asigna una predicción (clase o valor numérico).

Definición 4: Impureza de un nodo.
Sea S un subconjunto de datos con proporciones de clase $p_1, \ldots, p_k$. Una medida de impureza cuantifica qué tan mezcladas están las clases en el nodo.

Definición 5: Entropía.
La entropía de un nodo S se define como:

$$H(S) = -\sum_{i=1}^{k} p_i \log_2 p_i.$$

La entropía es máxima cuando las clases están uniformemente distribuidas y mínima (cero) cuando el nodo es puro.

Definición 6: Ganancia de información.
Sea S un conjunto de datos y sea una partición inducida por una característica que lo divide en subconjuntos $S_1, \ldots, S_m$.
La **ganancia de información** se define como:

$$IG(S) = H(S) - \sum_{j=1}^{m} \frac{|S_j|}{|S|} H(S_j).$$

Esta cantidad mide la reducción de entropía producida por la partición. El árbol selecciona la característica que maximiza la ganancia de información.

Definición 7: Índice de Gini.
Otra medida de impureza es el índice de Gini:

$$\text{Gini}(S) = 1 - \sum_{i=1}^{k} p_i^2.$$

El índice de Gini es cero cuando el nodo es puro y aumenta cuando las clases están más mezcladas.

En la construcción del árbol, en cada nodo se elige la partición que:

- Maximiza la ganancia de información, o
- Minimiza el índice de Gini ponderado.

Un árbol profundo puede ajustarse perfectamente a los datos de entrenamiento, pero perder capacidad de generalización. Para evitar sobreajuste se utilizan técnicas como:

- poda (*pruning*),
- restricción de profundidad máxima,
- mínimo número de muestras por nodo.